

2036 프리모템

AI 신약설계의 화학공간 붕괴

“모델이 좁아진 것이 아니라,
모델에 이의를 제기하는 사람이 먼저 좁아졌다.”

1. 예견된 실패 — 2036년 WHO 국제 청문회

다제내성균(AMR) 사망 궤적이 예측대로 진행되던 시점, 감사단이 항생제 개발 정책의 실체를 공개한다

임상 파이프라인은 2023년 97개 → 2025년 90개로 줄어든 뒤,
그 추세가 꺾이지 않은 채 2036년 약 60개 수준까지 쪼그라들었다.

그중 새로운 계열·표적·기전을 가진 “혁신” 후보는 단 10개뿐 —
2025년 WHO가 경고했던 16.7%라는 비율이 10년 넘게 그대로다.




카바페넴 내성균에 대응할 신규 계열 후보는 여전히 없다.

청문회에 소환된 한 원로 의약화학자는 이렇게 증언한다 —

“우리는 새로운 질문을 던지는 법을 잊었다.”

근거 자료 — 실측 데이터에 기반한 추세와 격차

Evidence anchoring the 2036 antibiotic-discovery premortem




Panel A: solid = reported WHO figures (2023, 2025); open markers/dashed = mechanical extrapolation holding the 2023→2025 annual rate (−3.7%/yr) and the 2025 innovative-fraction (16.7%) constant — a deliberately conservative floor that adds no further collapse-driven diversity loss. Panels B and C are non-comparable domains (reported antibacterial candidates vs. a general molecular-generation benchmark) shown as separate lines of evidence, not a single ratio. Sources: WHO 2025 antibacterial pipeline report; WHO/Lancet Microbe 2024 pipeline analysis; scaffold-coverage benchmark (general de novo molecular generation study).

근거 보강 — 민감도 분석: 예측이 특정 가정 하나에 기대지 않는다


연간 감소율 가정을 실측치(-3.68%/yr) 기준 $\pm 2\%$ p 흔들어도 결론은 유지됨

민감도 분석 - 연간 감소율 가정을 $\pm 2\%$ p 흔들어도 결론(파이프라인·혁신후보 모두 위축)은 유지된다

전체 파이프라인: 감소율 $\pm 2\%$ p 범위에서도 축소 유지



혁신 후보: 가장 낙관적 가정(연 -1.68%)에서도 15개 밑돌



2. 원인 진단 — 10년에 걸친 습관의 누적

2027년경 · 내부 설문 신호

화학자 상당수가 “AI 제안을 검토는 하지만 반박하지는 않는다”고 답함 — 반박이란 곧 AI가 놓친 스캐폴드를 직접 합성해 실패시켜보는 탐색적 실험

구조적 배경 · 실패 데이터가 새지 않는 이유

온톨로지 부재가 아니라 경쟁사 간 영업비밀·지적재산 문제 — ChEMBL·BAO 표준은 이미 있지만, “왜 실패했는지”는 특허·논문화되지 않는 한 기업 서랍 밖으로 안 나감

매 재학습 주기 · 재귀적 재학습 → mode collapse

제안되는 신규 화합물 수는 줄지 않았으나(매년 수백 개), 그 물질들이 공유하는 고유 스캐폴드 수는 감소 — “물질 수”와 “화학적 종 수”의 간극

감사단의 결론: “모델이 좁아진 것이 아니라, 모델에 이의를 제기하는 사람이 먼저 좁아졌다.”

인터뷰 인용 — 현장의 목소리

실패 데이터 미공유와 창의성 침식에 대한 두 개의 독립적 증언

사례 A — 실패 데이터 비공유

“...an AI model for drug discovery will be mostly deprived of information on the many hidden failures.”

“...estimates that the more-open pharmaceutical companies publish only about 15-30% of their data.”

— Miraz Rahman, 의약화학자, King's College London
(Nature, "Four ways to power-up AI for drug discovery," 2025)

→ 공개 문헌은 “성공한” 화합물에 편중되고, 실패 데이터의 70-85%는 기업 내부에 갇혀 AI 모델에 전달되지 않는다는 정량적 추정.

사례 B — 창의성 침식

“It's getting quite good at predicting things which we could predict before...”

“What I would really want from an AI/ML is to give me an idea I'd never think of...”

— 글로벌 제약회사 소속 의약화학자 인터뷰 응답자
(Lucy Sabin, University of Sheffield 연구 소개, Drug Discovery World, 2025)

→ AI를 부정하지 않지만, 기존에 알려진 것을 반복 확인하는 데 그친다는 인식. “예상 밖의 발견”을 기대하지만 얻지 못한다는 진술.

원인 진단 보장 — 이 붕괴 메커니즘은 낯선 것이 아니다

이미지 생성·추천 시스템·LLM에서 이미 관찰된 “재귀적 재학습 → 다양성 수렴” 패턴과의 비교

타 도메인 비교 — 반복 자기학습에 의한 다양성 붕괴는 낯선 현상이 아니다

신약설계 스캐폴드 수렴과 동일한 메커니즘(생성물로 다음 세대를 재학습)이 이미 여러 생성 AI 분야에서 관찰됨

도메인	관찰된 수렴 메커니즘	다양성 손실의 구체적 증상
이미지 생성 (diffusion / GAN)	자기 출력으로 재학습을 반복하면 세대를 거듭할수록 표현 다양성이 줄어드는 model collapse 현상 (Shumailov et al., 2023/2024, Nature)	이미지 다양성 지수 저하, 분포 꼬리(희귀 패턴) 소실
추천 시스템 (협업 필터링)	사용자 클릭 로그로 재학습을 반복하면 추천 폭이 인기 항목 주변으로 수렴하는 필터 버블 / 에코 챔버 현상	노출 카탈로그 다양성 감소, 비주류 항목 발견 확률 저하
대규모 언어모델 (합성데이터 학습)	AI 생성 텍스트를 학습 데이터에 다시 섞어 넣을 때 어휘·문체 다양성이 줄고 출력이 수렴	n-gram 다양성 저하, 희귀 어휘·문체 소실
신약설계 (이 제안의 시나리오)	화학자의 반박 없는 승인 + 미공유 실패 데이터가 누적되며, 재학습마다 제안 스캐폴드가 기존 계열로 수렴	스캐폴드 고유 개수 감소, 신규 계열 비율 정체(16.7%)


공통 패턴: 생성물이 다음 세대 학습 데이터의 일부가 되고, 사람의 반박/수정 신호가 약해질수록 수렴이 가속된다.

가시화 1 — 서로 다른 질문, 같은 답으로의 수렴

서로 다른 질문, 하나로 수렴하는 답 — 2036년 AI 신약설계의 다양성 붕괴 예시

사람 1의 질문


"세균이 방광 세포에 붙지 못하게 하려면?"



FimH adhesin (PDB 1KLF)
— 예방 표적: 부착 억제

사람 2의 질문

"이미 감염된 환자를 어떻게 치료하나?"




PBP2a (PDB 1VQQ)
— 치료 표적: 세포벽 합성 억제

AI 신약설계 엔진

재귀적 재학습
(mode / model collapse)

다양한 질문 →
좁아진 스캐폴드 후보 풀

결과: 같은 페니실린(베타락탐) 계열 스캐폴드
(76.9%가 기존 계열 재조합)



출발 질문(예방 vs. 치료)이 달랐음에도
두 요청 모두 동일 스캐폴드 계열로 회신됨


예시 도식: FimH-PBP2a는 실제 PDB 구조(1KLF, 1VQQ)이며, 우측 스캐폴드는 WHO/Lancet Microbe(2024)가 보고한 기존-계열 재사용 경향(10/13, 76.9%)을 나타내는 베타락탐 계열의 예시 구조 — 특정 실제 AI 출력 로그가 아닌 개념도임.

가시화 2 — AI의 4단계 추론: 왜 수렴이 일어나는가

AI 신약설계의 추론 과정 — 서로 다른 질문이 같은 답으로 수렴하는 이유


사람 1의 질문

AI의 4단계 추론: 인코딩 → 분포 참조 → 확신도 채점 → 수렴



"세균이 방광 세포에 붙지 못하게 하려면?"
(예방 표적: FimH adhesin, PDB 1KLF)
★ = 오른쪽 지도의 초록 별

사람 2의 질문



"이미 감염된 환자를 치료하려면?"
(치료 표적: PBP2a, PDB 1VQQ)
★ = 오른쪽 지도의 자주색 별

3) 재귀적 재학습 후 남은
고밀도 영역(=자주 학습된
기준계열, 예: 베타락탐)

2) 전체 가능 화학공간
(화색 점: 신규·희귀 스캐폴드,
원래는 더 많았음)


4) '확신도'를 친속도로 채점
→ 두 경로 모두 같은 좁은
고밀도 지점으로 수렴

1) 질문을 벡터로 인코딩
(목표는 다르지만 서로 다른
출발점에서 시작)

구조적 참신성/다양성 →

FimH(1KLF)-PBP2a(1VQQ)는 실제 PDB 구조, 중앙 산점도는 실제 모델 임베딩이 아닌 mode/model collapse 메커니즘을 나타낸 개념적 도식.
출력 스캐폴드는 특정 AI 로그가 아닌 76.9% 기준계열 유사성 경향을 나타내는 예시 구조.

두 질문의 최종 출력



동일 계열 스캐폴드
(베타락탐 코어, 개념도)

왜 위험한가?

예방과 치료라는 서로 다른 임상적
목표에서 출발했지만, 모델의 확신도
채점 기준이 '친속도'이기 때문에
두 경로 모두 같은 좁은 후보군으로
안내된다. 질문의 다양성이 출력의
다양성으로 이어지지 못한다.

실측 근거: 2024년 신규 진입 항생제
후보 13개 중 10개(76.9%)가 기존
계열 재조합 (WHO/Lancet Microbe)

3. 대응 방안 — 지금(2026년) 실행 가능한 세 갈래

1) 음성 결과 레지스트리 의무화

실패한 스캐폴드와 그 이유(독성·침투실패·대사불안정성 등)를 특허·논문 여부와 무관하게 등록, 학습데이터에 명시적으로 포함

2) “합성 데이터 오염도” 라벨링

매 재학습 세대마다 제안 스캐폴드의 다양성 지수를 공시, 모델이 이전 세대 자신의 출력에 얼마나 의존했는지 투명화

3) “AI-off” 가설 생성 세션 의무화

의약화학자가 AI 제안 없이 스스로 새로운 화학 공간을 상상하는 훈련을 정기적으로 제도화 — 반박의 근육이 위축되지 않도록

냉정한 단서: 이 세 조치는 “새로운 질문을 던지는 능력”은 되살릴 수 있어도, 이미 10년간 좁아진 화학 공간을 되돌리는 데는 또 다른 10년이 필요하다.

정책결정자용 체크리스트

AI 신약설계 화학공간 붕괴 방지를 위한 3대 실행 항목

1 음성결과(실패 데이터) 레지스트리 의무화

임상 전 단계 실패 화합물(비활성·독성·합성 실패 포함)을
중앙 레지스트리에 등록 의무화 — 신약 승인·특허 출원과 연동



등록 항목: 표적, 구조, 실패 단계, 실패 사유(활성 없음/독성/
합성 불가 등) 최소 4개 필드



국가 R&D 자금 지원 조건에 “실패 데이터 제출” 포함
(공공 자금 투입 프로젝트부터 단계적 적용)



비공개 기간(엠바고) 최대 24개월 후 자동 공개 조항



2 “합성데이터 오염도” 라벨링 제도

AI 생성 학습 데이터셋에 대해 “실측 대비 합성데이터 비율”
표기 의무화 (예: 데이터시트 형태, 모델 카드 확장)



재귀적 재학습(모델이 자신의 이전 출력으로 재학습) 이력
최소 2세대까지 추적·공시



규제기관 심사 시 “합조 화학공간 다양성 지표”(예: 스케폴드
커버리지) 제출을 신약 후보 선정 서류에 포함



3 “AI-off” 가설생성 세션 의무화

신약 발굴 조직 내 정기 워크숍 — AI 도구 없이 화학자가
독립적으로 신규 스케폴드 가설 제안 (분기 1회 이상 권장)

AI 제안과 인간 제안을 분리 기록·비교하는 내부 감사 절차
도입 (“검토하되 반박하지 않는” 관성 방지)

신진 연구자 교육과정에 “AI 비의존 가설 생성” 모듈 포함

냉정한 단서

10년간 좁아진 화학공간을 복원하는 데에는 또 다른 10년이 필요하다.
위 조치는 상황을 되돌리는 것이 아니라, 더 나빠지는 속도를 늦추는 것이다.
지금 시작해도 늦다 — 하지만 시작하지 않으면 더 늦는다.

반론 대응 — 심사위원이 던질 법한 질문에 미리 답한다

예견된 실패 시나리오와 근거 자료에 대한 세 가지 예상 반론과 대응 논리

Q1

왜 다른 요인(예산 삭감, 규제 변화, 항생제 시장 실패)은 배제했나?

배제한 것이 아니라 초점을 좁힌 것이다. 시장 실패·규제 문제는 이미 널리 논의된 기존 원인이며, 이 제안은 그중 상대적으로 덜 조명된 “AI 설계 파이프라인 내부의 다양성 침식” 메커니즘에 집중한다. 다른 요인들과 상호작용하며 위기를 가속하는 하나의 축으로 제시한 것이지, 유일한 원인이라고 주장하지 않는다.

Q2

선형 외삽이 너무 단순하지 않은가? 파이프라인 감소가 계속 같은 속도로 이어질 이유는?

그래서 민감도 분석을 별도로 수행했다. 연간 감소율을 실측치(-3.68%/yr) 기준 $\pm 2\%$ p 흔들어도 2036년 혁신 후보 수는 가장 낙관적 가정에서조차 2025년 실측치(15개)에 못 미친다. 또한 이 외삽은 model collapse로 인한 추가 다양성 손실을 반영하지 않은 보수적 추정치이며, 실제 궤적은 더 나쁠 수 있다는 점을 제안서에 명시했다.

Q3

“화학자가 반박하지 않는다”는 습관적 요인을 수치로 증명할 수 있나?

직접적인 정량 지표는 없다 — 이 부분은 정성적 인터뷰 근거(Sheffield대 연구, Nature의 Miraz Rahman 사례)에 기반한 해석이며, 제안서에서도 “내부 설문 신호”로 표현해 확정된 사실이 아닌 시나리오적 추론임을 명시했다. 이 제안의 핵심 기여는 정량 증명이 아니라, 실측 데이터(파이프라인·계열 편중)와 알려진 기술적 메커니즘(model/mode collapse)을 하나의 그럴듯한 인과 사슬로 연결하는 것이다.

출처 및 방법론 노트

- WHO (2025). Analysis of antibacterial agents in clinical and preclinical development — 파이프라인 90개, 혁신후보 15개(16.7%)
- WHO / The Lancet Microbe (2024) — 신규 진입 후보 13개 중 10개 기존계열(76.9%)
- Naghavi, M. et al. (2024). The Lancet — AMR 직접 사망 2021년 114만 명 → 2050년 191만 명 전망
- 일반 소분자 de novo 생성 벤치마크 — 참조 라이브러리 15,851개 vs. 생성 고유 스캐폴드 2,900개
- Sheffield 대학 연구진 인터뷰 (Drug Discovery World, 2025) — 의약화학자 창의성 침식 체감
- King, A. (2025). Nature — King's College London, Miraz Rahman 사례 (실패데이터 미공유, DOI: 10.1038/d41586-025-00602-5)
- Model/mode collapse 메커니즘 — 생성 AI 재귀적 재학습에 관한 문헌 (다양성 손실, 예: Shumailov et al.)

수치 산정: 2036년 파이프라인 규모(60개)·혁신 후보 수(10개)는 WHO 실측치(2023→2025)의 연간 감소율 (약 -3.7%/yr)과 2025년 혁신 비율(16.7%)을 고정해 11년 외삽한 보수적 추정치 — model collapse로 인한 추가 다양성 손실은 반영하지 않음. 민감도 분석(슬라이드 4)은 이 가정을 $\pm 2\%$ p 흔든 결과. 중앙 산점도·