

2036 프리모템

AI 신약설계의 화학공간 붕괴

“모델이 좁아진 것이 아니라,
모델에 이의를 제기하는 사람이 먼저 좁아졌다.”

1. 예견된 실패 — 2036년 WHO 국제 청문회

다제내성균(AMR) 사망 궤적이 예측대로 진행되던 시점, 감사단이 항생제 개발 정책의 실체를 공개한다

임상 파이프라인은 2023년 97개 → 2025년 90개로 줄어든 뒤,
그 추세가 꺾이지 않은 채 2036년 약 60개 수준까지 쪼그라들었다.

그중 새로운 계열·표적·기전을 가진 “혁신” 후보는 단 10개뿐 —
2025년 WHO가 경고했던 16.7%라는 비율이 10년 넘게 그대로다.


카바페넴 내성균에 대응할 신규 계열 후보는 여전히 없다.

청문회에 소환된 한 원로 의약화학자는 이렇게 증언한다 —

“우리는 새로운 질문을 던지는 법을 잊었다.”

근거 자료 — 실측 데이터에 기반한 추세와 격차

Evidence anchoring the 2036 antibiotic-discovery premortem




Panel A: solid = reported WHO figures (2023, 2025); open markers/dashed = mechanical extrapolation holding the 2023→2025 annual rate (−3.7%/yr) and the 2025 innovative-fraction (16.7%) constant — a deliberately conservative floor that adds no further collapse-driven diversity loss. Panels B and C are non-comparable domains (reported antibacterial candidates vs. a general molecular-generation benchmark) shown as separate lines of evidence, not a single ratio. Sources: WHO 2025 antibacterial pipeline report; WHO/Lancet Microbe 2024 pipeline analysis; scaffold-coverage benchmark (general de novo molecular generation study).

근거 보강 — 민감도 분석: 예측이 특정 가정 하나에 기대지 않는다


연간 감소율 가정을 실측치(-3.68%/yr) 기준 $\pm 2\%$ p 흔들어도 결론은 유지됨

민감도 분석 - 연간 감소율 가정을 $\pm 2\%$ p 흔들어도 결론(파이프라인·혁신후보 모두 위축)은 유지된다

전체 파이프라인: 감소율 $\pm 2\%$ p 범위에서도 축소 유지



혁신 후보: 가장 낙관적 가정(연 -1.68%)에서도 15개 밑돌



2. 원인 진단 — 10년에 걸친 습관의 누적

2027년경 · 내부 설문 신호

화학자들이 “AI 제안을 검토는 하지만 반박하지는 않는다”고 답함 — 당시엔 생산성 지표로 읽힘

계속 · 실패 데이터 미공유

“침투는 되지만 독성 있음”, “논문엔 없지만 이미 폐기함” 같은 지식이 화학자 개인의 서랍에만 남음

매 재학습 주기 · 재귀적 재학습

검토·반박 없이 승인된 이전 세대 제안 + 출판편향에 갇힌 문헌을 그대로 재학습 → 스캐폴드 다양성 점진적 감소

감사단의 결론: “모델이 좋아진 것이 아니라, 모델에 이의를 제기하는 사람이 먼저 좋아졌다.”

원인 진단 보강 — 이 붕괴 메커니즘은 낯선 것이 아니다

이미지 생성·추천 시스템·LLM에서 이미 관찰된 “재귀적 재학습 → 다양성 수렴” 패턴과의 비교

타 도메인 비교 — 반복 자기학습에 의한 다양성 붕괴는 낯선 현상이 아니다

신약설계 스캐폴드 수렴과 동일한 메커니즘(생성물로 다음 세대를 재학습)이 이미 여러 생성 AI 분야에서 관찰됨

도메인	관찰된 수렴 메커니즘	다양성 손실의 구체적 증상
이미지 생성 (diffusion / GAN)	자기 출력으로 재학습을 반복하면 세대를 거듭할수록 표현 다양성이 좁아지는 model collapse 현상 (Shumailov et al., 2023/2024, Nature)	이미지 다양성 지수 저하, 분포 꼬리(희귀 패턴) 소실
추천 시스템 (협업 필터링)	사용자 클릭 로그로 재학습을 반복하면 추천 폭이 인기 항목 주변으로 수렴하는 필터 버블 / 에코 챔버 현상	노출 카탈로그 다양성 감소, 비주류 항목 발견 확률 저하
대규모 언어모델 (합성데이터 학습)	AI 생성 텍스트를 학습 데이터에 다시 섞어 넣을 때 어휘·문체 다양성이 줄고 출력이 수렴	n-gram 다양성 저하, 희귀 어휘·문체 소실
신약설계 (이 제안의 시나리오)	화학자의 반박 없는 승인 + 미공유 실패 데이터가 누적되며, 재학습마다 제안 스캐폴드가 기존 계열로 수렴	스캐폴드 고유 개수 감소, 신규 계열 비율 정체(16.7%)


공통 패턴: 생성물이 다음 세대 학습 데이터의 일부가 되고, 사람의 반박/수정 신호가 약해질수록 수렴이 가속된다.

가시화 1 — 서로 다른 질문, 같은 답으로의 수렴

서로 다른 질문, 하나로 수렴하는 답 — 2036년 AI 신약설계의 다양성 붕괴 예시

사람 1의 질문


"세균이 방광 세포에 붙지 못하게 하려면?"



FimH adhesin (PDB 1KLF)
— 예방 표적: 부착 억제

사람 2의 질문

"이미 감염된 환자를 어떻게 치료하나?"




PBP2a (PDB 1VQQ)
— 치료 표적: 세포벽 합성 억제

AI 신약설계 엔진

재귀적 재학습
(mode / model collapse)

다양한 질문 →
좁아진 스캐폴드 후보 풀

결과: 같은 페니실린(베타락탐) 계열 스캐폴드
(76.9%가 기존 계열 재조합)



출발 질문(예방 vs. 치료)이 달랐음에도
두 요청 모두 동일 스캐폴드 계열로 회신됨

예시 도식: FimH-PBP2a는 실제 PDB 구조(1KLF, 1VQQ)이며, 우측 스캐폴드는 WHO/Lancet Microbe(2024)가 보고한 기존-계열 재사용 경향(10/13, 76.9%)을 나타내는 베타락탐 계열의 예시 구조 — 특정 실제 AI 출력 로그가 아닌 개념도임.


가시화 2 — AI의 4단계 추론: 왜 수렴이 일어나는가

AI 신약설계의 추론 과정 — 서로 다른 질문이 같은 답으로 수렴하는 이유

사람 1의 질문


AI의 4단계 추론: 인코딩 → 분포 참조 → 확신도 채점 → 수렴

두 질문의 최종 출력



"세균이 방광 세포에 붙지 못하게 하려면?"
(예방 표적: FimH adhesin, PDB 1KLF)
★ = 오른쪽 지도의 초록 별

사람 2의 질문



"이미 감염된 환자를 치료하려면?"
(치료 표적: PBP2a, PDB 1VQQ)
★ = 오른쪽 지도의 자주색 별

↑ 학습데이터 내 희소성

3) 재귀적 재학습 후 남은 고밀도 영역(=자주 학습된 기존계열, 예: 베타락탐)


2) 전체 가능 화학공간 (회색 점: 신규·희귀 스캐폴드, 원래는 더 넓었음)

4) '확신도'를 친숙도로 채점 → 두 경로 모두 같은 고밀도 지점으로 수렴

1) 질문을 벡터로 인코딩 (목표는 다르지만 서로 다른 출발점에서 시작)

→ 구조적 참신성/다양성 →

FimH(1KLF)-PBP2a(1VQQ)는 실제 PDB 구조. 중앙 산점도는 실제 모델 임베딩이 아닌 mode/model collapse 메커니즘을 나타낸 개념적 도식. 출력 스캐폴드는 특정 AI 로그가 아닌 76.9% 기존계열 유사성 경향을 나타내는 예시 구조.



동일 계열 스캐폴드 (베타락탐 코어, 개념도)

왜 위험한가?
예방과 치료라는 서로 다른 임상적 목표에서 출발했지만, 모델의 확신도 채점 기준이 '친숙도'이기 때문에 두 경로 모두 같은 좁은 후보군으로 안내된다. 질문의 다양성이 출력의 다양성으로 이어지지 못한다.

실측 근거: 2024년 신규 진입 항생제 후보 13개 중 10개(76.9%)가 기존 계열 재조합 (WHO/Lancet Microbe)

3. 대응 방안 — 지금(2026년) 실행 가능한 세 갈래

1) 음성 결과 레지스트리 의무화

실패한 스캐폴드와 그 이유(독성·침투실패·대사불안정성 등)를 특허·논문 여부와 무관하게 등록, 학습데이터에 명시적으로 포함

2) “합성 데이터 오염도” 라벨링

매 재학습 세대마다 제안 스캐폴드의 다양성 지수를 공시, 모델이 이전 세대 자신의 출력에 얼마나 의존했는지 투명화

3) “AI-off” 가설 생성 세션 의무화

의약화학자가 AI 제안 없이 스스로 새로운 화학 공간을 상상하는 훈련을 정기적으로 제도화 — 반박의 근육이 위축되지 않도록

냉정한 단서: 이 세 조치는 “새로운 질문을 던지는 능력”은 되살릴 수 있어도, 이미 10년간 좁아진 화학 공간을 되돌리는 데는 또 다른 10년이 필요하다.

출처 및 방법론 노트

- WHO (2025). Analysis of antibacterial agents in clinical and preclinical development — 파이프라인 90개, 혁신후보 15개(16.7%)
- WHO / The Lancet Microbe (2024) — 신규 진입 후보 13개 중 10개 기존계열(76.9%)
- Naghavi, M. et al. (2024). The Lancet — AMR 직접 사망 2021년 114만 명 → 2050년 191만 명 전망
- 일반 소분자 de novo 생성 벤치마크 — 참조 라이브러리 15,851개 vs. 생성 고유 스캐폴드 2,900개
- Sheffield 대학 연구진 인터뷰 (Drug Discovery World, 2025) — 의약화학자 창의성 침식 체감
- Nature 기사 — King's College London, Miraz Rahman 사례 (미출판 실패데이터 미공유 문제)
- Model/mode collapse 메커니즘 — 생성 AI 재귀적 재학습에 관한 문헌 (다양성 손실, 예: Shumailov et al.)

수치 산정: 2036년 파이프라인 규모(60개)·혁신 후보 수(10개)는 WHO 실측치(2023→2025)의 연간 감소율 (약 -3.7%/yr)과 2025년 혁신 비율(16.7%)을 고정해 11년 외삽한 보수적 추정치 — model collapse로 인한 추가 다양성 손실은 반영하지 않음. 민감도 분석(슬라이드 4)은 이 가정을 $\pm 2\%$ p 혼돈 결과. 중앙 산점도·화학구조 예시는 개념적 도식이며 실제 AI 출력 로그 아님.